LE JULÉ | Matriz de costos

Entrega final Coderhouse · Automatización de mensajes con Notion, Make, OpenAI, Gmail y Telegram

Propósito: comparar el costo de generación de IA en un flujo inmediato frente a opciones de optimización. Los valores son supuestos ilustrativos, no precios vigentes verificados ni facturación real.

1. Arquitectura y unidades de consumo

Cada mensaje aprobado atraviesa: registro en Notion → consulta de conocimiento → generación de texto con OpenAI → revisión humana → envío por Gmail y/o Telegram → actualización de Notion. La IA se consume durante la generación, no durante la aprobación.

Variable	Supuesto del modelo	Justificación
Volumen	1.000 mensajes / mes	Escenario de referencia, no dato observado
Entrada por mensaje	600 tokens	Instrucciones + contexto RAG + datos
Salida por mensaje	150 tokens	Mensaje breve personalizado
Modelo	Modelo económico de texto; referencia ilustrativa	El escenario real utiliza gpt-5.4-mini; verificar tarifa antes de presupuestar
Tarifa de entrada	$0,40 USD / millón de tokens	Tarifa hipotética de cálculo
Tarifa de salida	$1,60 USD / millón de tokens	Tarifa hipotética de cálculo

2. Cálculo base y comparación

Tokens mensuales: entrada = 1.000 × 600 = 600.000; salida = 1.000 × 150 = 150.000. Costo = (tokens de entrada / 1.000.000 × tarifa entrada) + (tokens de salida / 1.000.000 × tarifa salida).

Escenario	Cálculo mensual de IA	Costo USD	Ahorro vs. base
A. Flujo inmediato (base)	(0,6 × $0,40) + (0,15 × $1,60)	$0,480	—
B. Batch hipotético (−50 %)	$0,480 × 0,50	$0,240	50 %
C. Caching hipotético	Entrada: 40 % cacheable a 50 % del precio; salida sin cambio	$0,432	10 %

Nota: Batch y caching son escenarios teóricos; descuentos, elegibilidad y compatibilidad deben validarse con las tarifas y funciones actuales del proveedor. No se afirma que estén implementados en el escenario.

3. Recomendación operativa

Para Le Julé: mantener el procesamiento inmediato en la ruta de generación cuando se necesita revisión humana rápida. Evaluar Batch solo para campañas masivas que toleren procesamiento diferido. Evaluar caching cuando exista un prefijo de prompt suficientemente repetido y compatible con el modelo/API.

4. Costos adicionales y límites del análisis

Componente	Tratamiento en esta matriz
Make	No incluido: depende de operaciones ejecutadas, plan y créditos consumidos.

Componente	Tratamiento en esta matriz
Notion	No incluido: depende del plan contratado y límites aplicables.
Gmail / Telegram	No se asigna costo marginal por mensaje; pueden existir límites de uso y políticas de envío.
Errores y reintentos	No incluidos en el escenario base; elevan operaciones y, si repiten llamadas de IA, tokens.
Trabajo humano HITL	No incluido: requiere estimación de minutos de revisión y costo/hora.

5. Indicadores y medición real

Costo IA por mensaje = costo total de tokens / mensajes generados. Ahorro estimado = (costo base − costo optimizado) / costo base × 100. Costo operativo total = IA + Make + licencias + revisión humana + reintentos. Registrar tokens de entrada/salida y número de ejecuciones para reemplazar los supuestos por datos reales.

6. Transparencia para la evaluación

Este documento presenta una matriz comparativa reproducible para cumplir el criterio de optimización. Los precios son ilustrativos y el resultado no equivale a una cotización oficial. La ruta HITL, filtros de aprobación, control de duplicados y envío dinámico por Gmail corresponden al diseño documentado del proyecto; Batch/Caching son oportunidades futuras, no capacidades activadas.

Versión: 24 de octubre de 2026 · Moneda: USD · Proyecto académico Le Julé